

# Decision Tree Classifier (Дерево решений)

Дорофеев Демид, Клюкин Павел  
М80-307Б-23

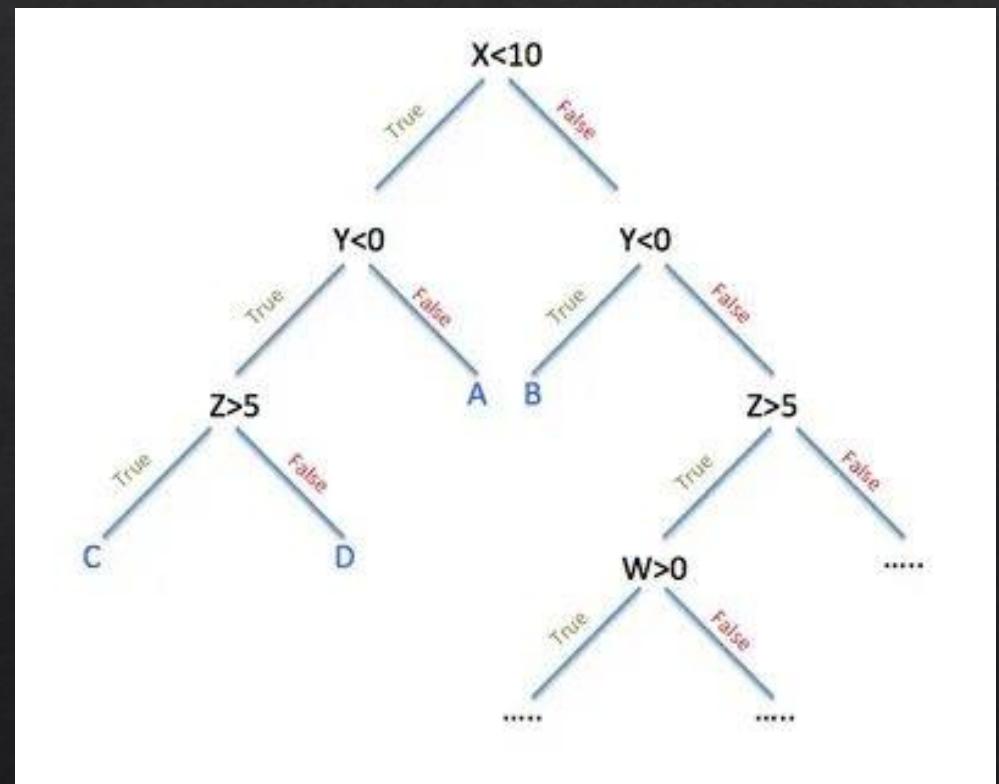
# Дерево решений

Преимущества:

- ❖ Простая интерпретация (можно визуализировать дерево).
- ❖ Не требует масштабирования данных.

Недостатки:

- ❖ Склонно к **переобучению**, особенно при большой глубине дерева.
- ❖ Может быть нестабильным (небольшие изменения данных → другое дерево).

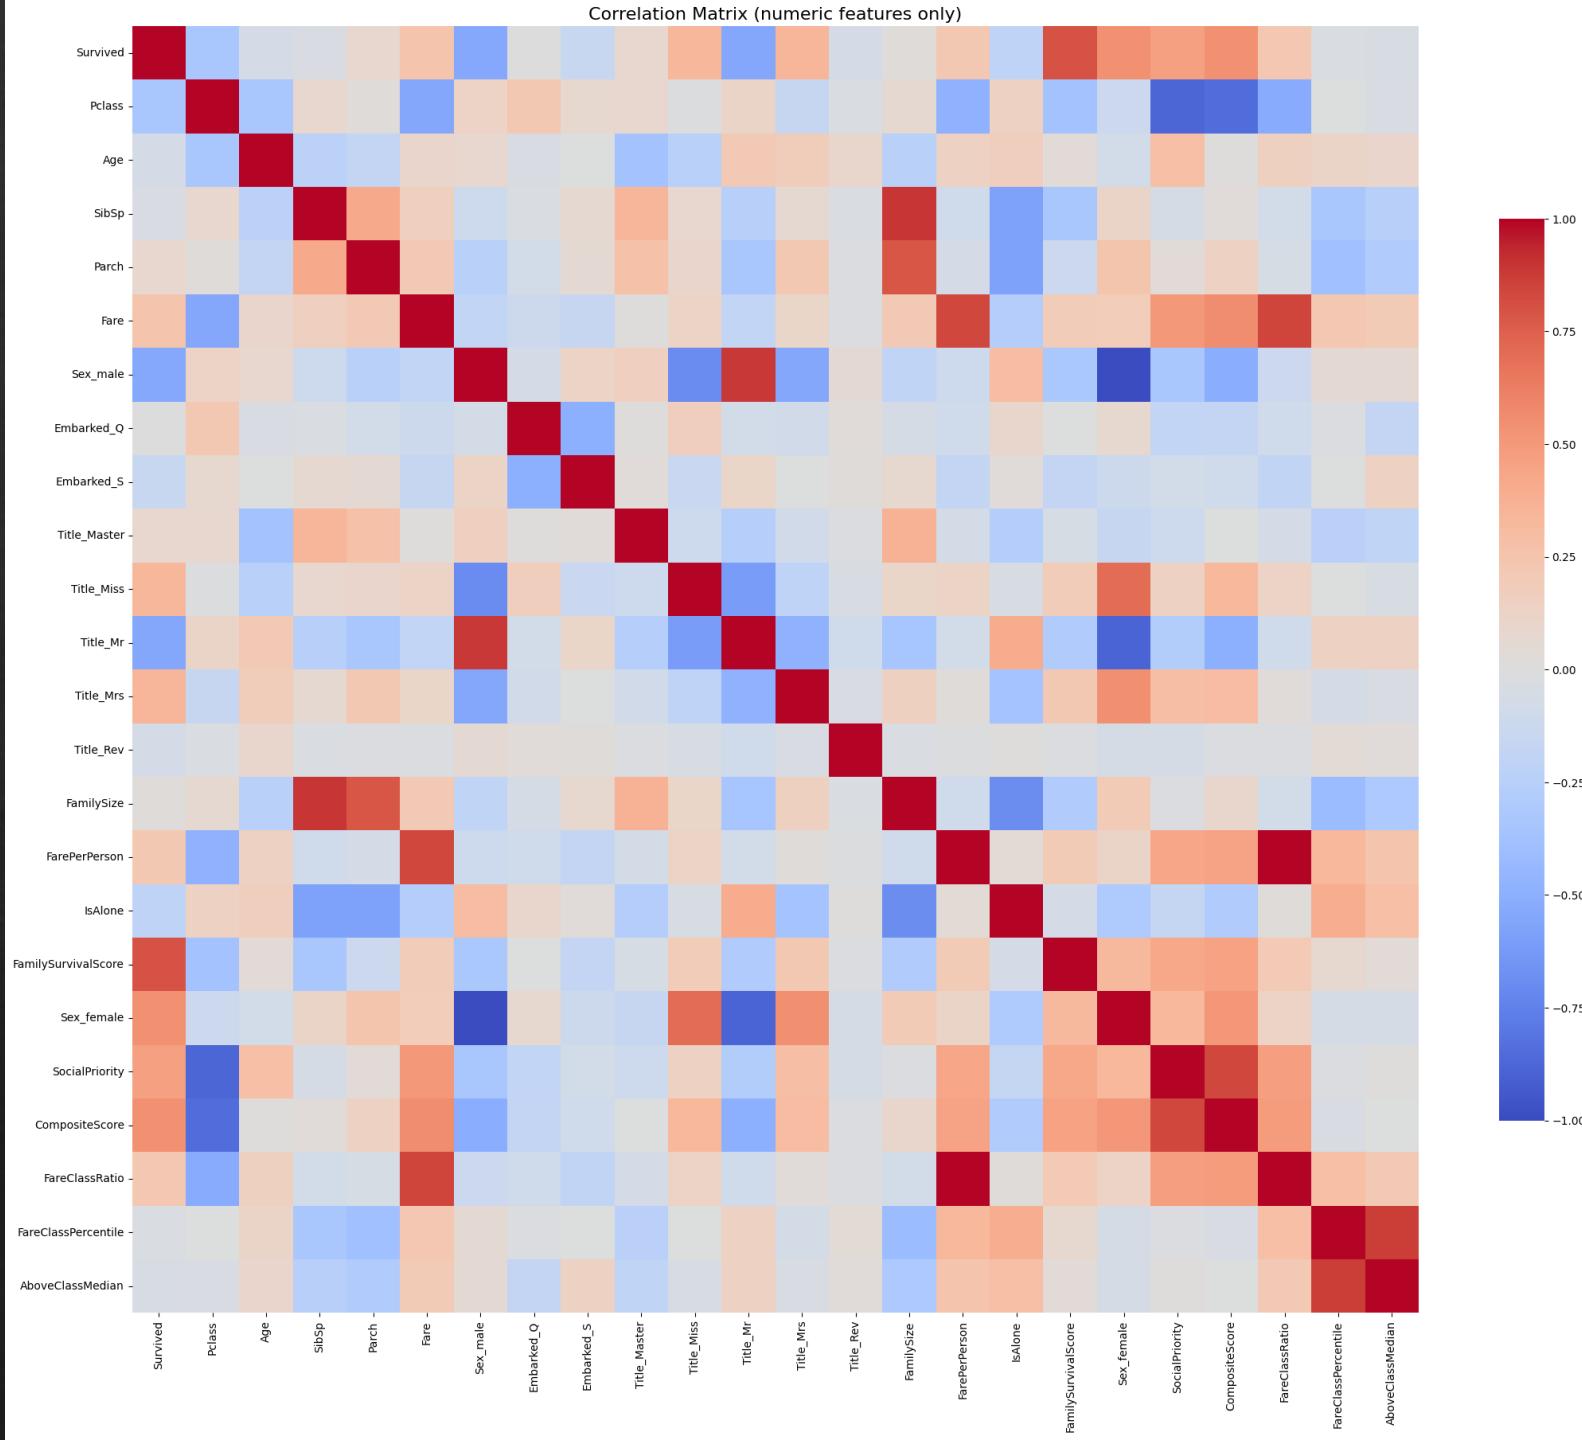


# Подготовка

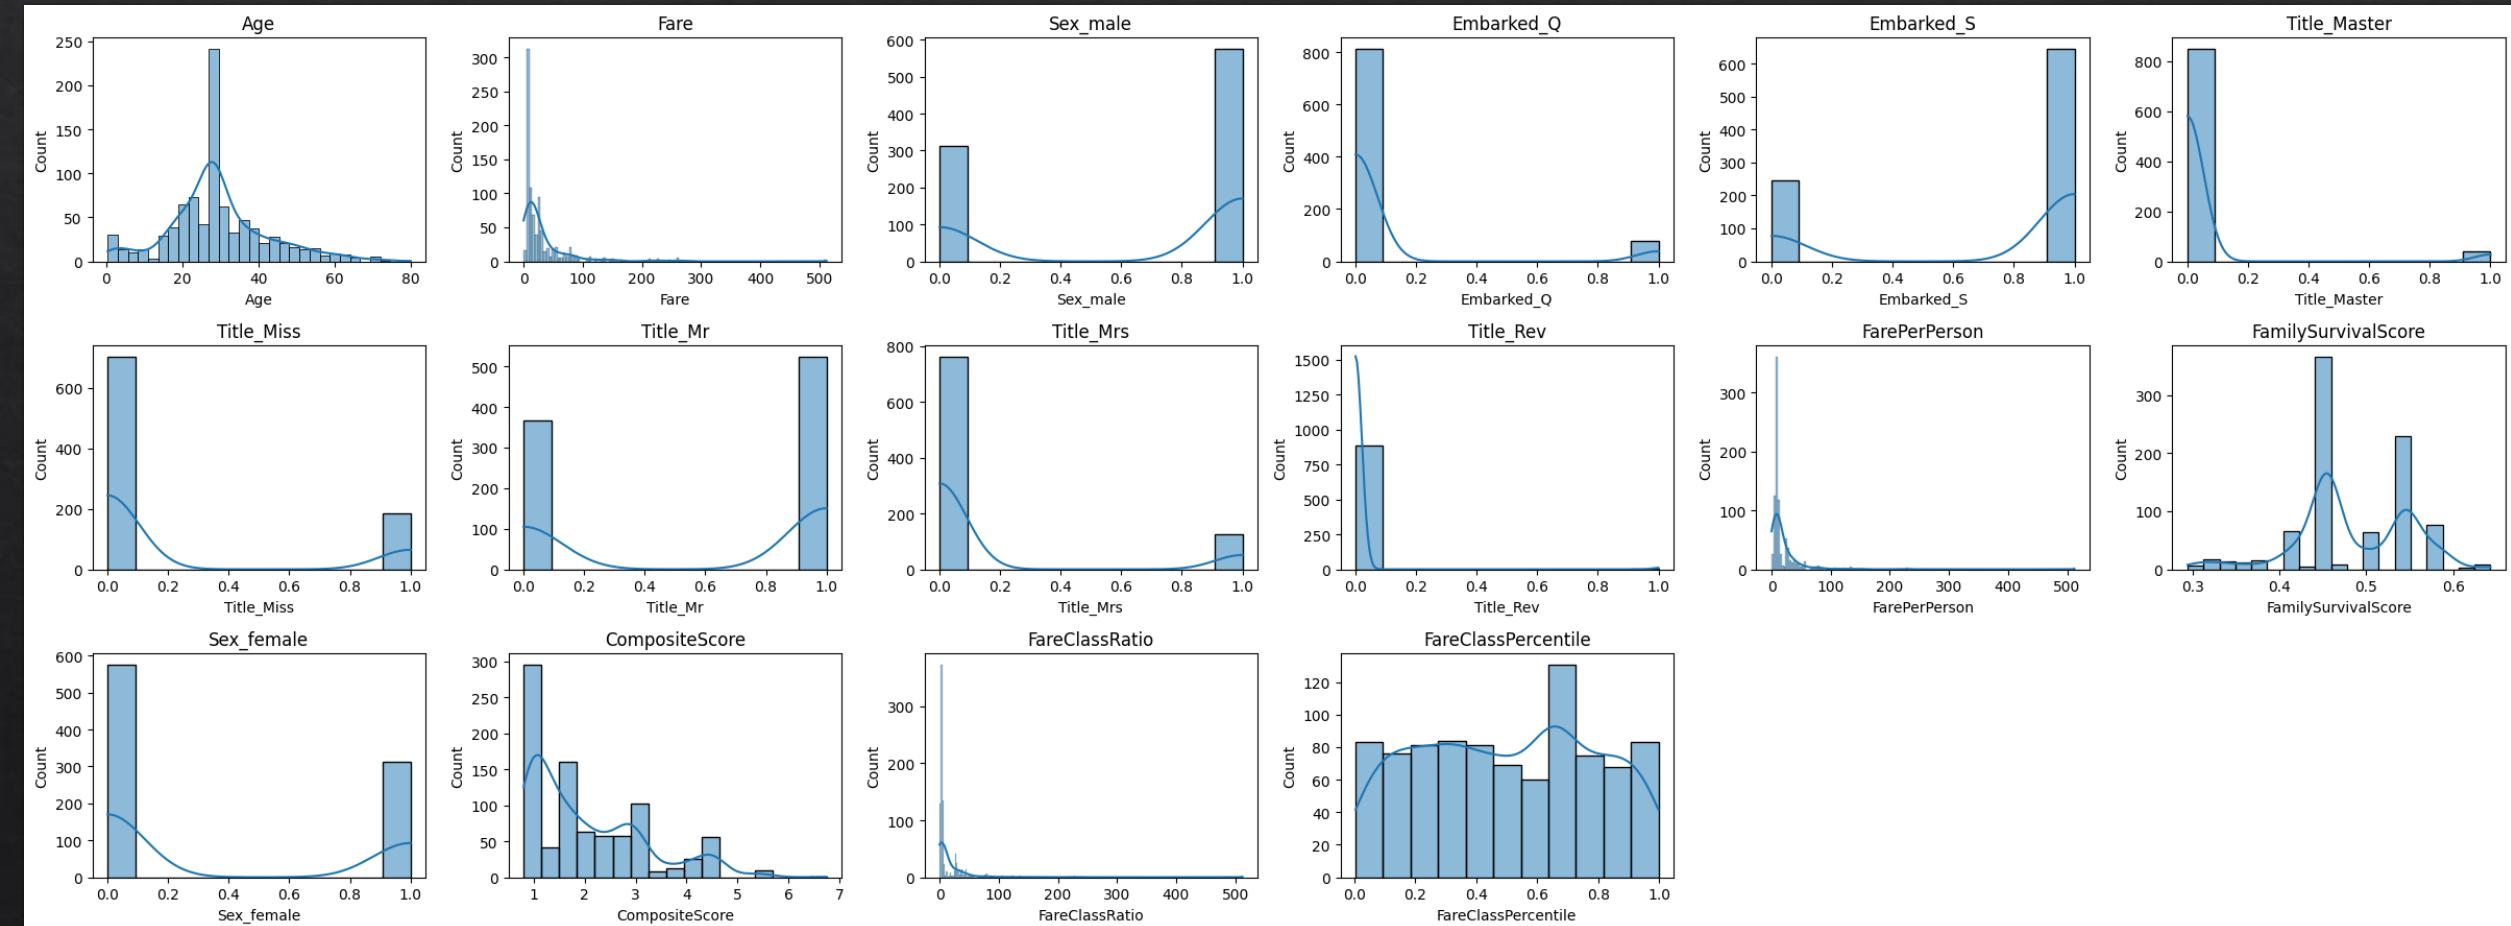
## Добавление новых features

PassengerI, Survived → Survived, Pclass, Age, SibSp, Parch, Fare, Sex\_male, Embarked\_Q, Embarked\_S, Title\_Master, Title\_Miss, Title\_Mr, Title\_Mrs, Title\_Rev, FamilySize, FarePerPerson, IsAlone, FamilySurvivalScore, Sex\_female, SocialPriority, CompositeScore, FareClassRatio, FareClassPercentile, AboveClassMedian, Archetype\_AveragePassenger, Archetype\_Businessman, Archetype\_PoorChild, Archetype\_RichChild, Archetype\_WealthyMother, Archetype\_WealthySingleWoman, Archetype\_WorkingClassMan

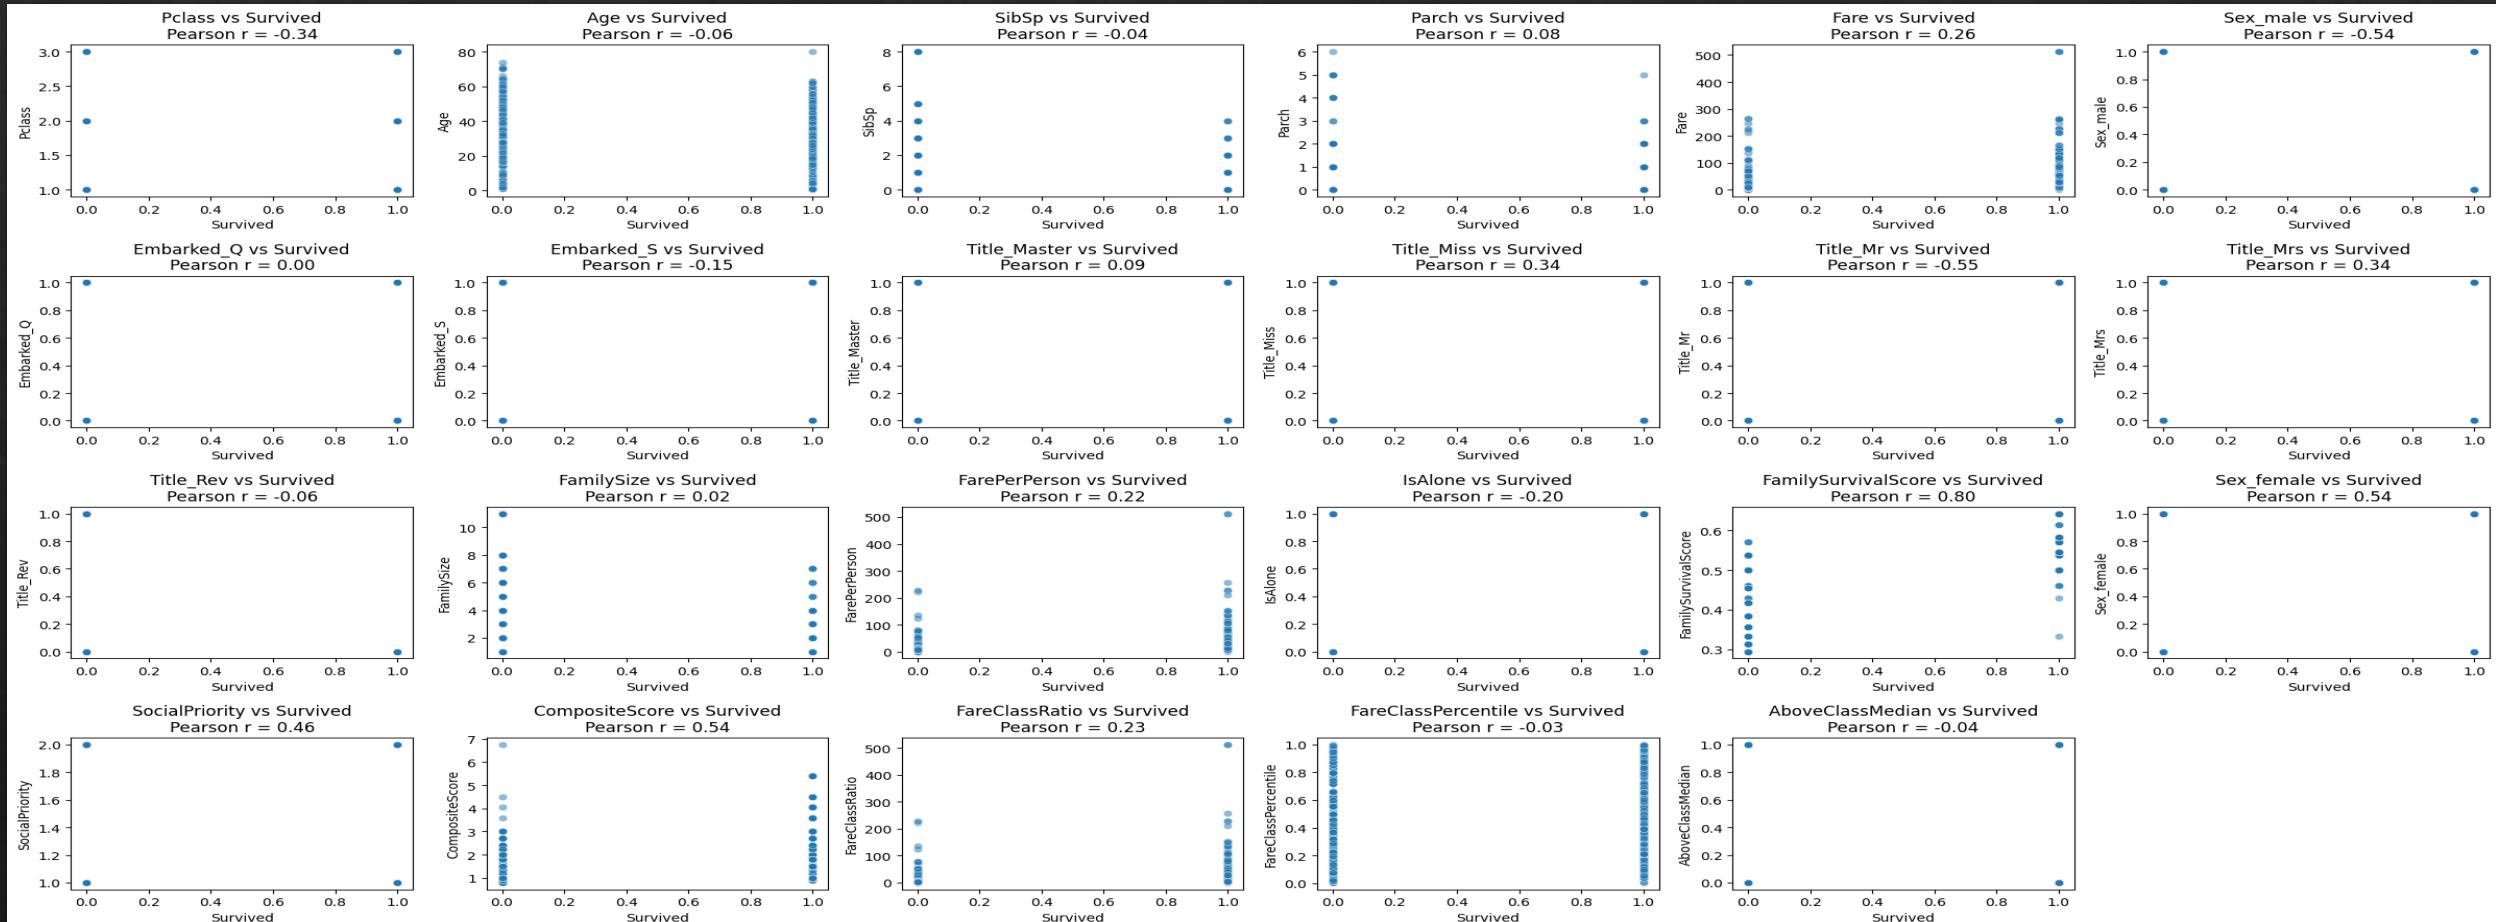
## Корреляционная матрица признаков



# Распределение данных



# Соотношение с целевой переменной + коэффициент пирсона

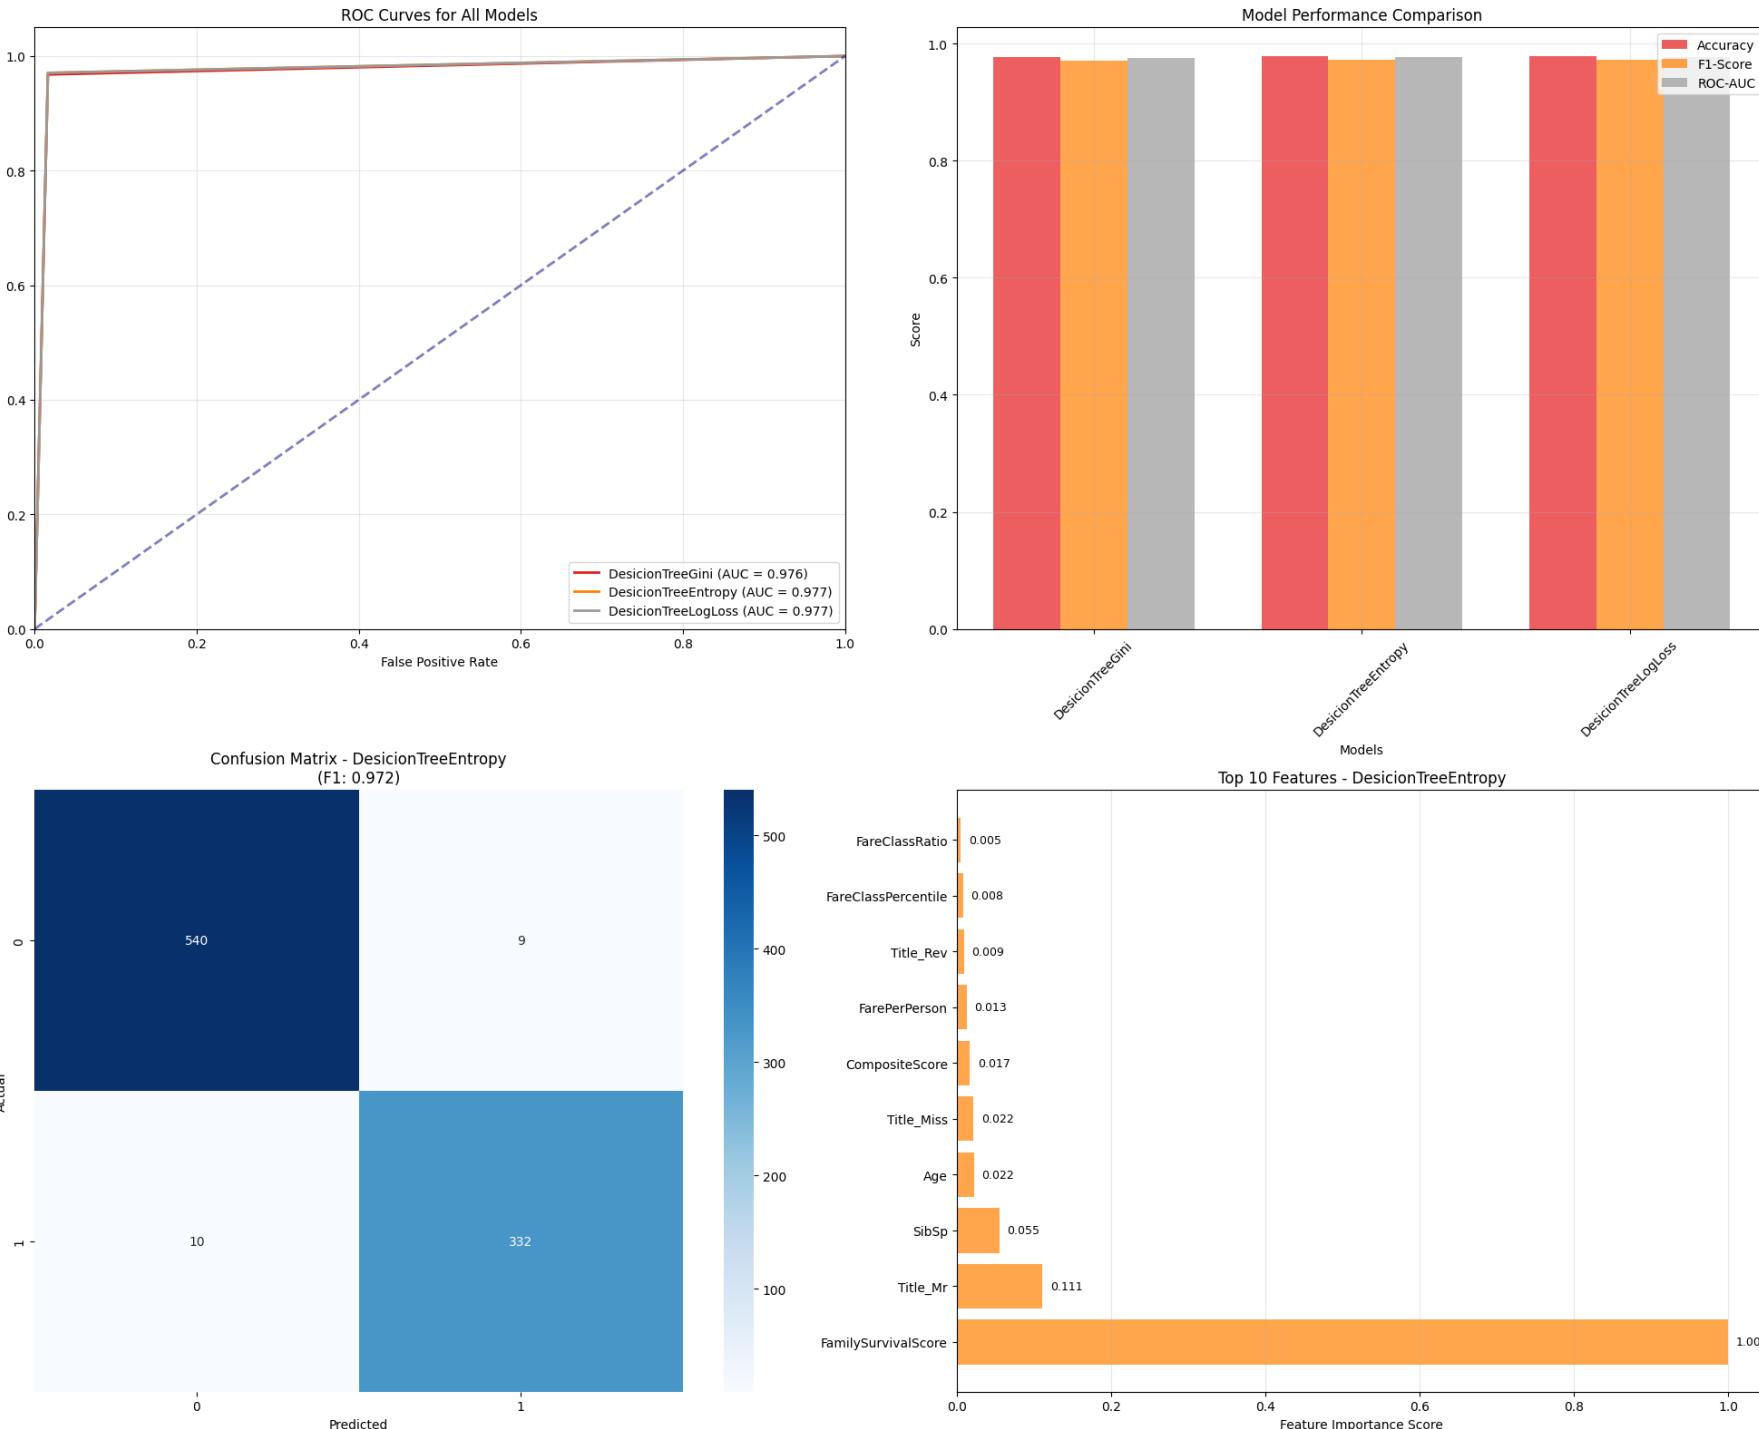


Критерий качества разбиения.

gini — индекс Джини

entropy — энтропия

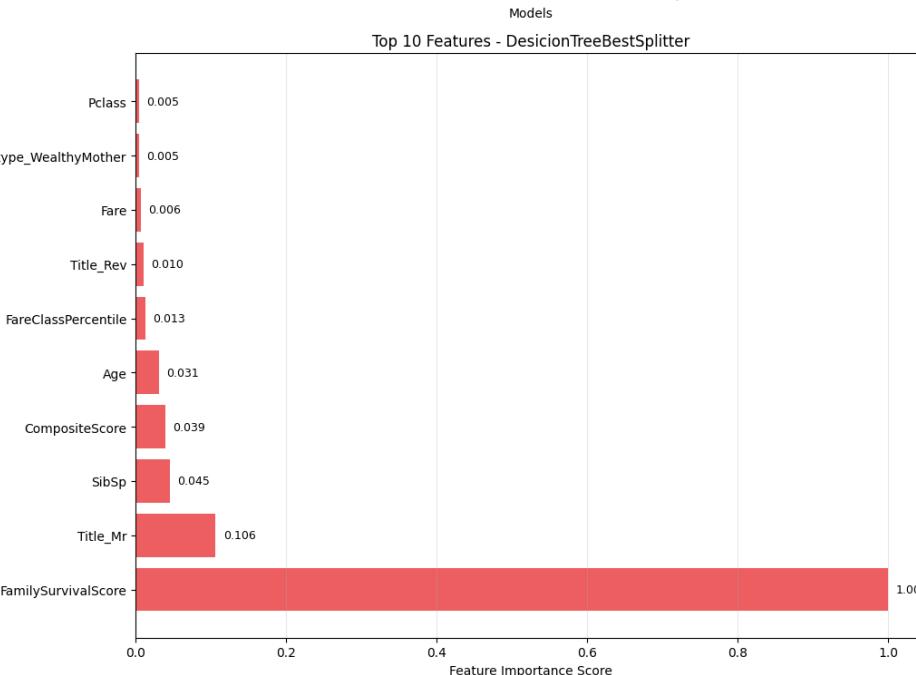
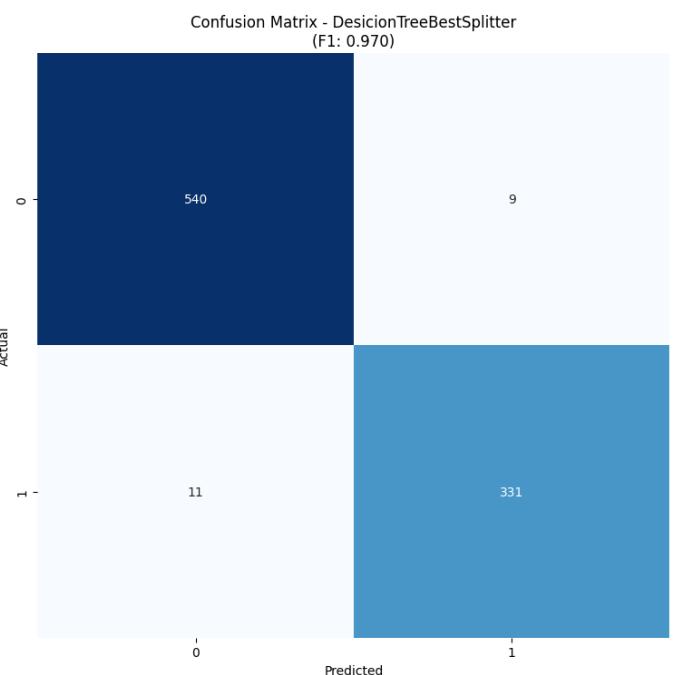
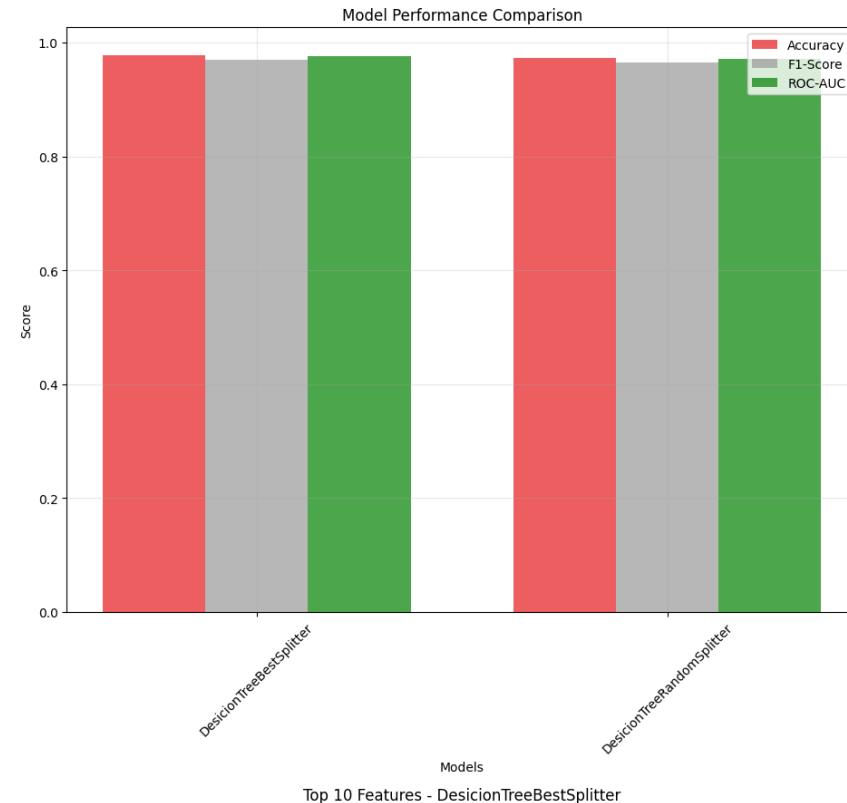
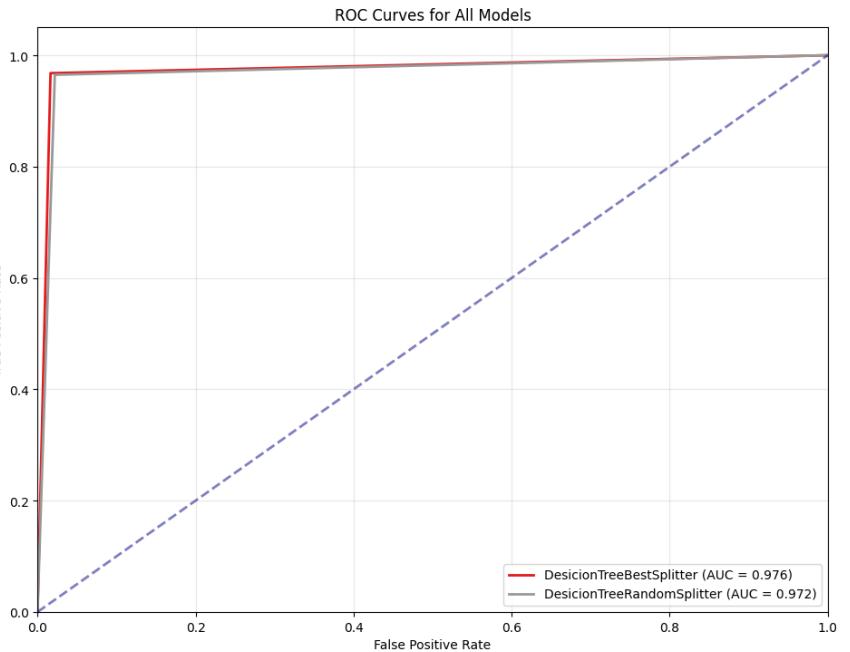
log\_loss — основан на логарифмической потере.



Стратегия выбора признака для разбиения.

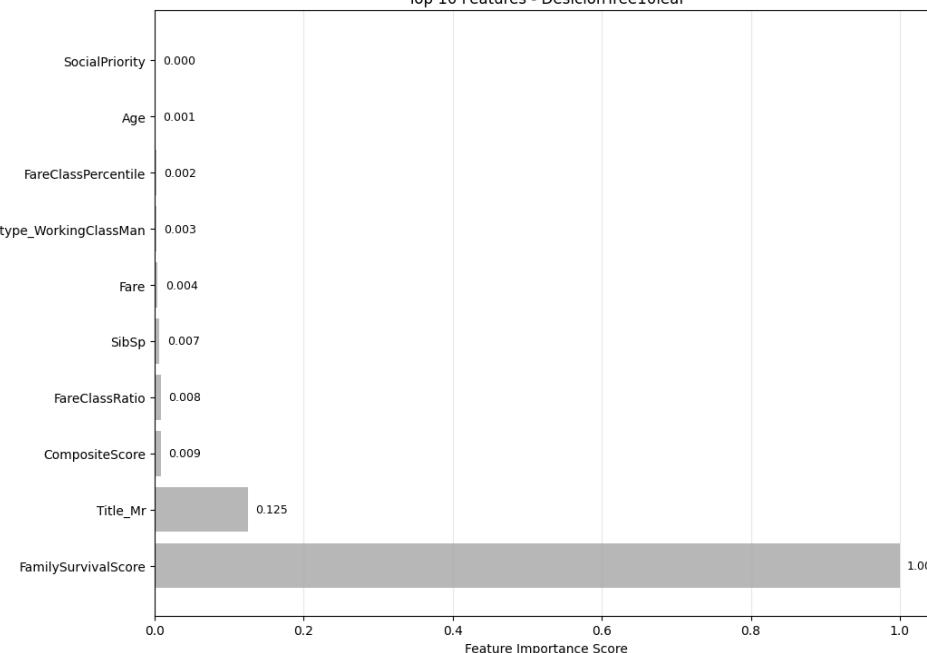
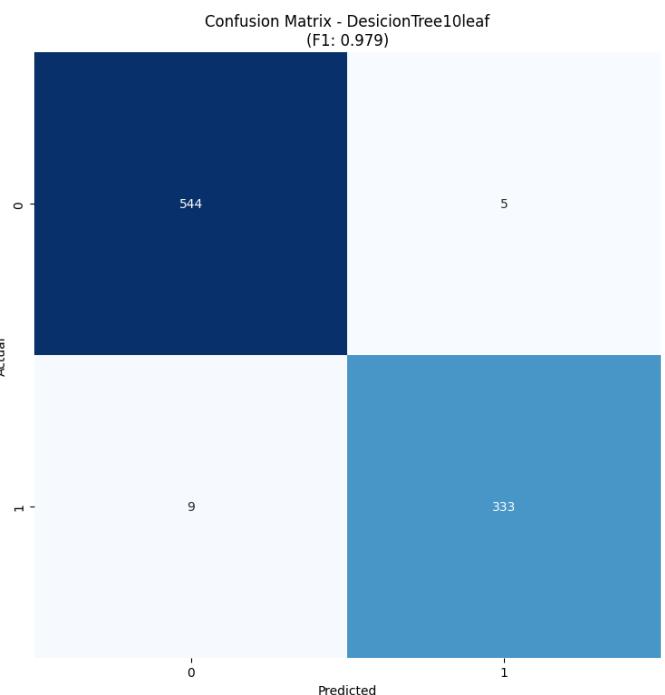
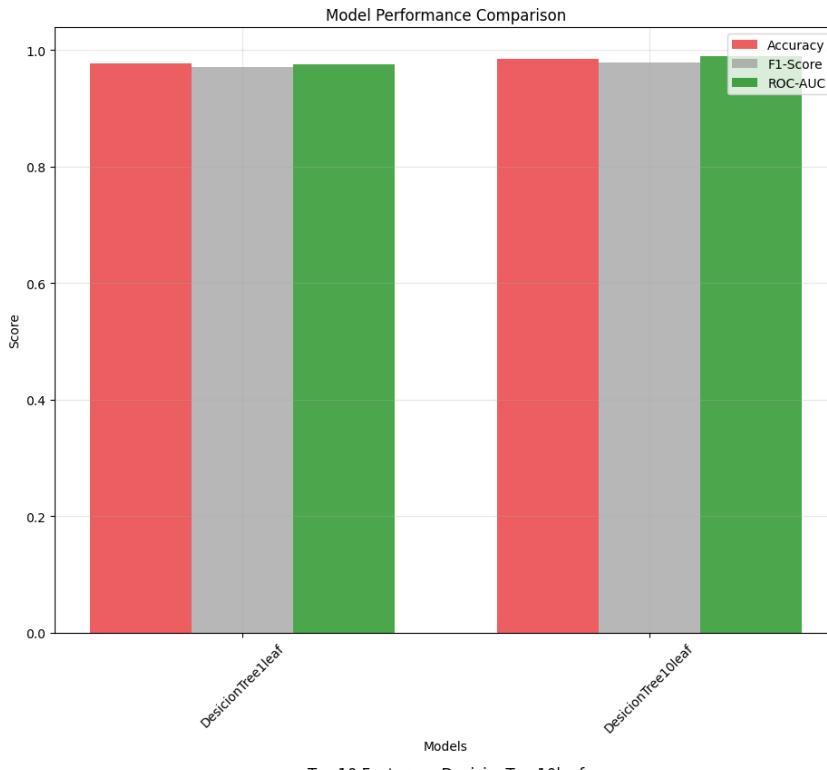
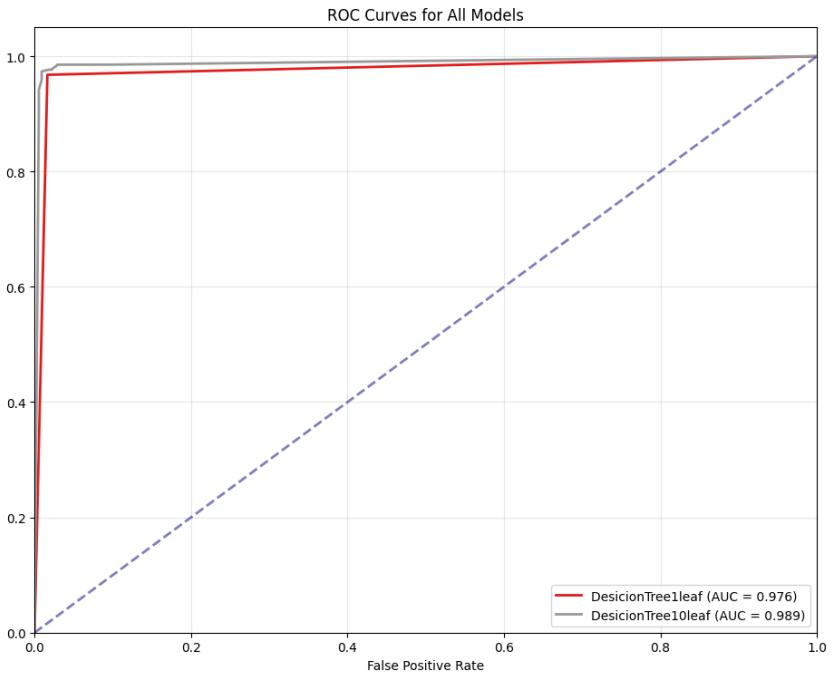
best — выбирает наилучшее разбиение

random' — выбирает случайный признак (для ускорения и разнообразия).



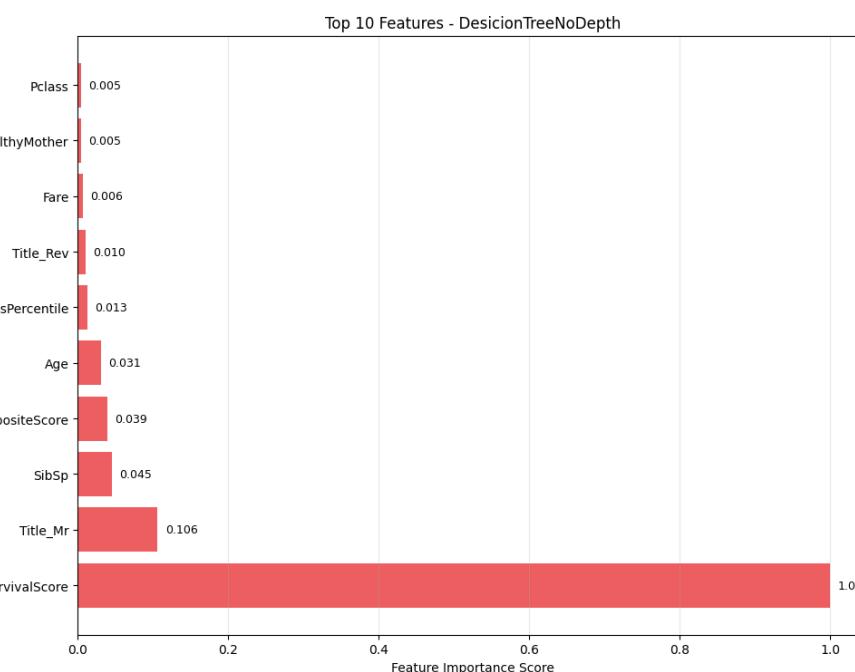
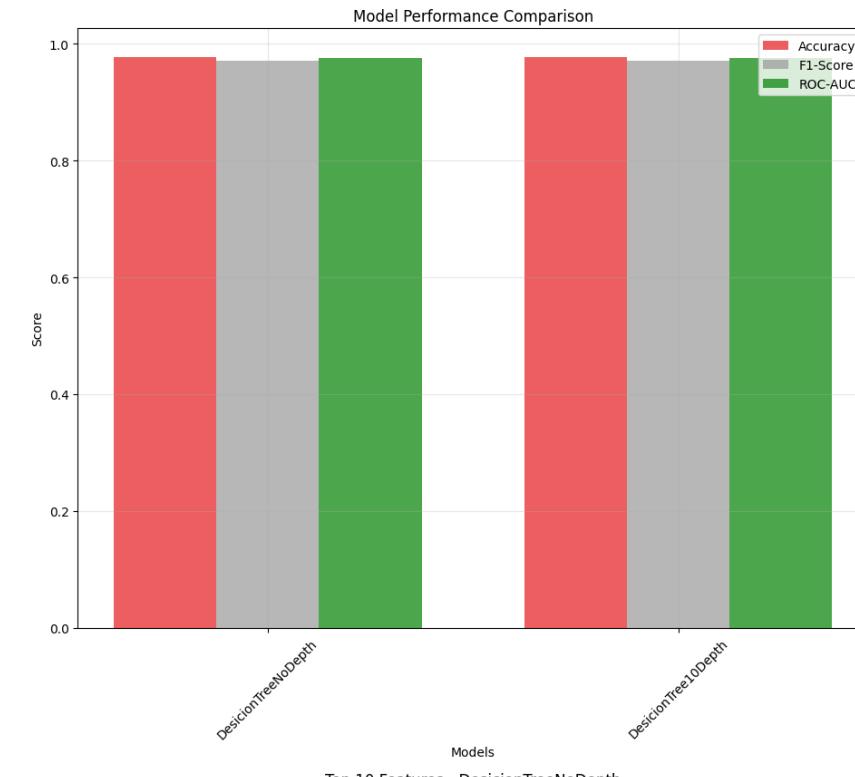
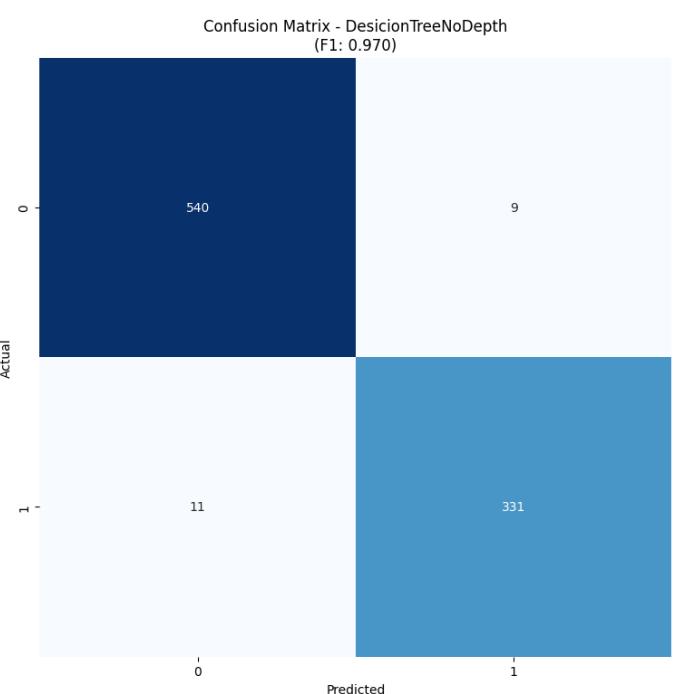
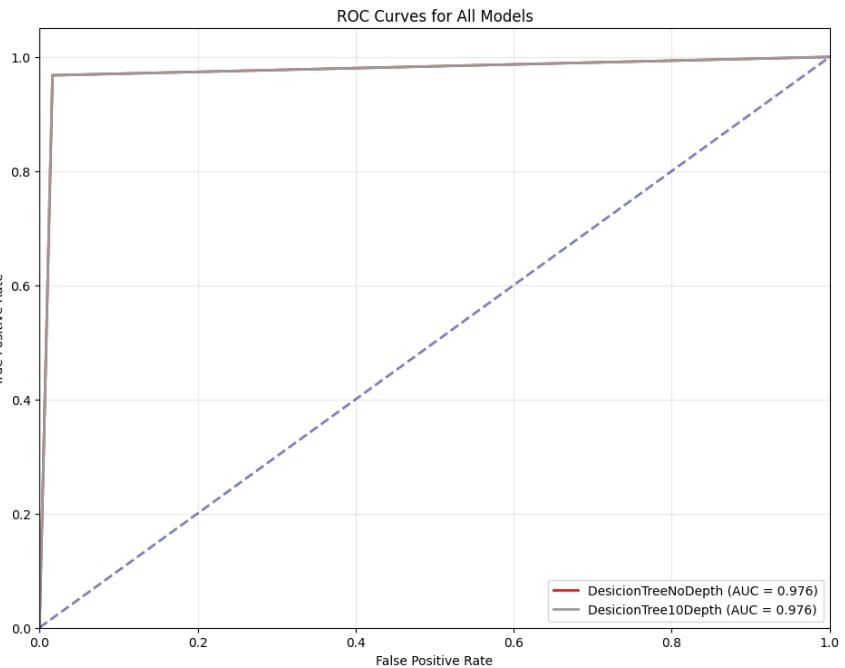
Минимальное количество образцов в листе.

Увеличение значения делает дерево более “гладким”.



Максимальная глубина дерева.

None — без ограничения  
(может привести к  
переобучению).



- ❖ criterion=gini
- ❖ splitter=best
- ❖ max\_depth=None
- ❖ min\_samples\_split=2
- ❖ min\_samples\_leaf=15
- ❖ random\_state=RANDOM\_STATE
- ❖ max\_features=None
- ❖ class\_weight=None

